

# Nhận dạng tôm bằng ShrimpNet dựa trên mạng thần kinh tích chập

## (Shrimp identification on convolutional neural network)

Nguyễn Tiến Dũng

Khoa Điện Tử Viễn Thông

Trường Đại học Bách Khoa – Đại học Đà Nẵng

Gmail: [ntdung.focus@gmail.com](mailto:ntdung.focus@gmail.com)

Dương Nam Hải

Khoa Điện Tử Viễn Thông

Trường Đại học Bách Khoa – Đại học Đà Nẵng

Gmail: [duongnamhai20@gmail.com](mailto:duongnamhai20@gmail.com)

Trần Công Nam Anh

Khoa Điện Tử Viễn Thông

Trường Đại học Bách Khoa – Đại học Đà Nẵng

Gmail: [namanh27092001@gmail.com](mailto:namanh27092001@gmail.com)

GVHD: Đào Duy Tuấn

Khoa Điện Tử Viễn Thông

Trường Đại học Bách Khoa – Đại học Đà Nẵng

Gmail: [ddtuan@dut.udn.vn](mailto:ddtuan@dut.udn.vn)

**T**ôm tắt - Tôm là mặt hàng thương mại quan trọng của thế giới, có giá trị kinh tế cao và cũng là một trong những nguồn cung cấp protein động vật quan trọng nhất. Xem xét chi phí tính toán và phần cứng, bài báo này trình bày kiến trúc mạng thần kinh tích chập (CNN) (được đặt tên là ShrimpNet) để nhận dạng tôm. ShrimpNet được đề xuất là một phần quan trọng của nuôi tôm thông minh, rất hữu ích cho nuôi tôm. ShrimpNet được đề xuất bao gồm hai lớp CNN và hai lớp được kết nối đầy đủ. Bộ dữ liệu được thu thập bao gồm sáu loại tôm khác nhau được sử dụng để đào tạo và kiểm tra hiệu suất của ShrimpNet được đề xuất. Kết quả thử nghiệm cho thấy ShrimpNet được đề xuất có độ chính xác 95,48% trong việc nhận dạng tôm. Do đó, ShrimpNet được đề xuất là một công cụ hữu ích với hiệu suất tốt để nhận dạng tôm.

### I. Giới thiệu

Với sự gia tăng dân số nhanh chóng, nhu cầu lương thực đang trở nên quan trọng hơn dưới hiệu ứng nhà kính và sự hoang hóa đất đai. Protein là nguồn dinh dưỡng không thể thiếu của con người. Cá là một nguồn protein động vật chính khác. Tôm là một trong những nguồn protein quan trọng nhất trong thủy sản và nó cũng là hàng hóa thương mại quan trọng của thế giới. Hơn nữa, đánh bắt cá biển đã dần được thay thế bằng nuôi trồng thủy sản (hoặc nuôi trồng thủy sản) trên biển do nguồn cá tự nhiên giảm và ô nhiễm nước.

Theo số liệu thống kê của Tổ chức Lương thực và Nông nghiệp Liên hợp quốc (FAO) năm 2014, sản lượng tôm toàn cầu năm 2014 vượt 4,58 triệu tấn và giá trị sản lượng đạt 23,5 tỷ USD. Dự kiến sẽ đạt 5 triệu tấn vào năm 2016 và giá trị sản lượng là 30 tỷ USD. Đối tượng nuôi chính là tôm thẻ chân trắng, chiếm 80% tổng sản lượng tôm toàn cầu. Vì vậy, tôm là đối tượng nuôi triển vọng, có giá trị kinh tế cao.

Tuy nhiên, nuôi tôm là công việc đòi hỏi nhân lực và thời gian cao. Vì vậy, một hệ thống nuôi tôm

thông minh sẽ giúp ích rất nhiều cho việc nuôi tôm. Công nhận tôm là một phần quan trọng của nuôi tôm thông minh. Kết quả thu được có thể là những ứng dụng tiếp theo trong nuôi tôm, góp phần nâng cao giá trị sản xuất nuôi tôm.

Trí tuệ nhân tạo (AI) là một trong những công nghệ có thể đạt được mục tiêu nuôi tôm thông minh. AI luôn là mục tiêu cuối cùng của nhân loại và Deep learning là một công nghệ thường được công nhận là gần gũi nhất với AI. Deep learning bắt chước khả năng xử lý đa cấp của hệ thống não bộ con người. Các nơ-ron cấp thấp hơn được sử dụng để xử lý thông tin cấp thấp. Các tế bào thần kinh cấp cao hơn được tận dụng để xử lý thông tin trừu tượng hơn. Một sự kết hợp của các phương pháp này được sử dụng để nắm bắt các đặc điểm phân biệt hơn của các đối tượng và do đó đạt được khả năng nhận thức của con người. Do đó, AI đã nhận được rất nhiều sự chú ý và nó đã thu hút thành công nhiều khoản đầu tư quan trọng vào các lĩnh vực xe tự lái (Chen và cộng sự 2016b), cánh tay robot (Qi và cộng sự 2015) và chẩn đoán y tế (Kononenko 1993).

Phát hiện, nhận dạng và phân loại đối tượng đóng vai trò quan trọng trong lĩnh vực thị giác máy tính. Tuy nhiên, rất nhiều công việc sơ bộ (tiền xử lý ảnh) là cần thiết để đạt được kết quả tốt của việc phát hiện, nhận dạng và phân loại đối tượng. Hơn nữa, các tính năng khả thi phải được phát hiện và trích xuất. Trong một thời gian dài, việc phát hiện, nhận dạng và phân loại đối tượng phụ thuộc vào các tính năng này (Hu et al. 2011, 2015; Huang et al. 2015; Wang và Chang 2011; Fan và Hung 2014). Do đó, việc lựa chọn các tính năng tốt là rất quan trọng để đạt được độ chính xác cao. Tuy nhiên, sự quan tâm đến các kỹ thuật Deep learning, chẳng hạn như mạng thần kinh tích chập (CNN), đã tăng lên trong thập kỷ qua. Nhìn chung, CNN đạt được những kết quả nổi bật trong lĩnh vực thị giác máy tính. Ưu điểm của CNN đến từ việc không cần xử lý trước rộng rãi và chọn các tính năng tốt.

Deep learning đã nhận được rất nhiều sự quan tâm và ưu ái, chủ yếu từ một số cuộc thi quan trọng. Năm 2009 (Märgner và Abed 2009), người chiến

thắng trong cuộc thi nhận dạng chữ viết tay đã được trao giải từ một mạng Deep learning sử dụng kiến trúc bộ nhớ ngắn hạn dài (LSTM). Vào năm 2012 (Krizhevsky et al. 2012), nhóm do Geoffrey Hinton chỉ đạo tại Đại học Toronto ở Canada đã xây dựng mạng nơ-ron sâu (DNN) trên bộ xử lý đồ họa (GPU) để giành chức vô địch trong cuộc thi nhận dạng hình ảnh do tổ chức. Thử thách nhận dạng hình ảnh quy mô lớn ImageNet (ILSVRC) nổi tiếng, trong đó mô hình AlexNet (Krizhevsky et al. 2012) được đề xuất để đánh giá trên bộ dữ liệu quy mô lớn ImageNet và AlexNet là một CNN bao gồm năm lớp CNN và ba lớp đầy đủ- các lớp kết nối (FC).

CNN là một kiến trúc phổ biến của Deep learning. CNN chủ yếu bao gồm các lớp tích chập, lớp nhóm, lớp được kết nối đầy đủ và lớp phân loại. Hơn nữa, CNN đã hình thành khá tốt trong các ứng dụng nhận dạng khuôn mặt, nhận dạng người đi bộ, nhận dạng phương tiện, phát hiện đối tượng (Krizhevsky et al. 2012; Zhao et al. 2019; Chen et al. 2016a; Xiao et al. 2017; Dong et al. 2014), v.v. Do đó, Deep learning dựa trên CNN rất phù hợp để sử dụng cho việc nhận dạng tôm.

Chen và cộng sự (2016a) đã đề xuất một thuật toán để xác minh khuôn mặt không bị hạn chế dựa trên các tính năng sâu của CNN. Để đào tạo, quá trình phát hiện khuôn mặt và mốc trên CASIA WebFace được thực hiện, sau đó bộ dữ liệu IJB-A được bản địa hóa và căn chỉnh từng khuôn mặt. Tiếp theo, chế độ CNN sâu được đào tạo trên CASIA-WebFace (Yi et al. 2014) và lấy được chỉ số Bayes chung bằng cách sử dụng tập huấn luyện của tập dữ liệu IJB-A và các tính năng CNN sâu. Bộ dữ liệu IJB-A bao gồm các khuôn mặt không giới hạn trong thế giới thực từ 500 đối tượng với đầy đủ các biến thể về tư thế và ánh sáng. Cuối cùng, đưa ra một cặp bộ ảnh thử nghiệm, điểm tương đồng dựa trên các tính năng CNN sâu của họ và số liệu đã học được tính toán. thu được, hồi quy softmax được sử dụng để phân loại các loại phương tiện. Phương pháp đề xuất có hiệu quả tốt trong việc phân loại loại phương tiện đã được thể hiện trong kết quả thực nghiệm. đối tượng với đầy đủ các biến thể về tư thế và ánh sáng. Cuối cùng, đưa ra một cặp bộ ảnh thử nghiệm, điểm tương đồng dựa trên

Việc xác thực khuôn mặt dựa trên các tính năng CNN sâu với hiệu suất tốt đã được thể hiện trong kết quả thử nghiệm.

Xiao và cộng sự (2017) đã đề xuất một khung Deep learning mới hoạt động để tìm kiếm người. Thay vì chia nó thành hai nhiệm vụ riêng biệt: phát hiện người đi bộ và nhận dạng lại người, nó cùng xử lý việc phát hiện và nhận dạng trong một CNN duy nhất. Hàm mất mát so khớp phiên bản trực tuyến (OIM) đã được đề xuất để đào tạo mạng một cách hiệu quả vì bản chất phi tham số của nó cho phép hội tụ nhanh hơn và tốt hơn. Tính hiệu quả của phương pháp đề xuất đã được xác thực bằng cách so sánh với các đường cơ sở khác trên tập dữ liệu này.

Dong và cộng sự (2014) đã đề xuất một phương pháp phân loại loại phương tiện dựa trên ngoại hình từ các hình ảnh nhìn từ phía trước của phương tiện bằng cách sử dụng CNN bán giám sát để tìm hiểu các đặc điểm tốt cho việc phân loại phương tiện. Mô hình được đề xuất có thể tự động học các tính năng phân biệt và đáng tin cậy để phân loại loại phương tiện bằng cách sử dụng bộ lọc thưa thớt được đào tạo trước. Chiến lược bỏ qua lớp trong mạng đảm bảo các tính năng cuối cùng bao gồm cả tính năng toàn cầu cấp cao và tính năng cục bộ cấp thấp. Sau các tính năng cuối cùng thu được, hồi quy softmax được sử dụng để phân loại các loại phương tiện. Phương pháp đề xuất có hiệu quả tốt trong việc phân loại loại phương tiện đã được thể hiện trong kết quả thực nghiệm.

Trong bài báo này, ShrimpNet được đề xuất để nhận dạng tôm khi xem xét chi phí tính toán và phần cứng. ShrimpNet được đề xuất là một kiến trúc Deep learning bao gồm hai lớp CNN và hai lớp FC, trong đó đơn vị tuyến tính được chỉnh lưu (ReLU) được sử dụng làm chức năng kích hoạt, sau đó sử dụng tổng hợp và loại bỏ tối đa. Tập dữ liệu được thu thập bao gồm sáu loại tôm khác nhau được sử dụng để đào tạo và kiểm tra hiệu suất của ShrimpNet được đề xuất. Kết quả thử nghiệm cho thấy ShrimpNet được đề xuất có độ chính xác 95,48% trong việc nhận dạng tôm.

Do đó, phương pháp được đề xuất là một công cụ hữu ích để nhận dạng tôm. Phát hiện, nhận dạng và

phân loại đối tượng đóng vai trò quan trọng trong lĩnh vực thị giác máy tính. Tuy nhiên, rất nhiều công việc sơ bộ (tiền xử lý ảnh) là cần thiết để đạt được kết quả tốt của việc phát hiện, nhận dạng và phân loại đối tượng. Hơn nữa, các tính năng khả thi phải được phát hiện và trích xuất. Vì vậy, việc lựa chọn các tính năng tốt là rất quan trọng để đạt được độ chính xác cao.

## II. Nghiên cứu liên quan về nuôi trồng thủy sản thông minh

Manytar và cộng sự (2017) đã đề xuất giao diện người máy (HMI) được tạo trên e-Shrimp như một hệ thống điều khiển thông minh cho ao nuôi tôm thẻ chân trắng nhằm tăng năng suất của ngành nuôi tôm. Trong phương pháp đề xuất của họ, HMI là một thiết bị tương tác giữa người dùng và e-Tôm. Mô-đun giám sát ao nuôi từ xa (RPM) định kỳ trên e-Shrimp sẽ cung cấp thông tin về tình trạng chất lượng nước ao nuôi trên HMI. HMI cũng có thể cung cấp thông báo cho người dùng dưới dạng báo động và dịch vụ tin nhắn ngắn (SMS) khi thông tin chất lượng nước của ao nuôi ở tình trạng bất thường. Bên cạnh đó, người dùng có thể sử dụng bàn phím để điều hướng các menu trên hệ thống e-Shrimp hoặc gửi tin nhắn SMS đến HMI để thực hiện thao tác mong muốn. Do đó, phương pháp đề xuất rất hữu ích cho nuôi tôm thông minh.


Fabregas và cộng sự. (2018) đã phát triển hệ thống phát hiện bệnh đốm trắng trên tôm. Trong hệ thống đề xuất, thuật toán kết hợp giữa mạng nơ-ron nhân tạo (ANN) và logic mờ được sử dụng để phát hiện vị trí của các đốm trắng và sự đổi màu trên cơ thể tôm. Hệ thống được đề xuất với tỷ lệ chính xác 90% đã được thể hiện trong kết quả thử nghiệm. Do đó, hệ thống được đề xuất là một công cụ hữu ích để phát hiện bệnh đốm trắng trên tôm.

Dabrowski và cộng sự. (2018) đã đề xuất một mô hình xác định các thông số chất lượng nước ngày đêm trong ao nuôi tôm nuôi thủy sản để cung cấp hỗ trợ cho người nuôi tôm trong ao. Mô hình đề xuất được xây dựng trong khuôn khổ fl tering Bayesian. Bộ lọc Kalman và bộ lọc Kalman không mùi được áp dụng để suy luận. Khả năng dự báo

ngắn hạn với sai số phần trăm tuyệt đối trung bình là từ 0,5 đến 11%. Do đó, phương pháp đề xuất có thể dự đoán chất lượng nước và sau đó tránh được sự suy giảm chất lượng nước.

### III. ShrimpNet để nhận dạng tôm

Kiến trúc Deep learning được đề xuất bao gồm hai lớp CNN và hai lớp FC, được đặt tên là ShrimpNet, để nhận dạng tôm. Trong ShrimpNet được đề xuất, tính năng tổng hợp tối đa, chức năng kích hoạt ReLU và loại bỏ được sử dụng, sau đó softmax được áp dụng làm trình phân loại. Kiến trúc học sâu được đề xuất là một tham chiếu từ Lenet-5 (Lecun và cộng sự 1998) và sau đó được sửa đổi thêm thành ShrimpNet, như trong Hình 1, trong đó nhân tích chập có kích thước  $5 \times 5$  và kích thước  $2 \times 2$  được sử dụng tối đa gộp lại. Softmax-6 là bộ phân loại Softmax và nó được sử dụng để lấy phân loại. Trình phân loại Softmax được xác định là biểu thức (1), trong đó  $\theta_1, \theta_2, \dots, \theta_k \in R^{n+1}$  tham số



**Hình 1.** Đề xuất ShrimpNet

$$h_{\theta}(x^{(i)}) = \begin{bmatrix} p(y^{(i)} = 1 | x^{(i)}; \theta) \\ p(y^{(i)} = 2 | x^{(i)}; \theta) \\ \vdots \\ p(y^{(i)} = k | x^{(i)}; \theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x^{(i)}}} \begin{bmatrix} e^{\theta_1^T x^{(i)}} \\ e^{\theta_2^T x^{(i)}} \\ \vdots \\ e^{\theta_k^T x^{(i)}} \end{bmatrix}$$


Phát hiện và trích xuất tính năng thu được trong tập hợp lớp định lượng. Mỗi lớp tích chập sử dụng tập hạt nhân riêng của nó để được tích hợp với đầu vào của lớp dẫn đến nhiều bản đồ đặc trưng. Đầu vào của bản đồ tính năng thứ  $i$  của lớp  $l$  là  $x^l_i$  có thể thu được bằng cách sử dụng biểu thức (2), trong đó

$w^l_{i,j}$  là hạt nhân (*kernel*) của chính nó và  $f$  là hàm kích hoạt (*activation function*). ReLU được sử dụng làm chức năng kích hoạt và được xác định trong biểu thức (3). Trong đề xuất ShrimpNet,  $w^l_{i,j}$  là hạt nhân tích chập  $5 \times 5$  (*convolutional kernel*). Hàm tổng hợp tối đa (*max pooling function*) được áp dụng cho các vùng bản đồ đặc trưng có kích thước  $2 \times 2$ . Giá trị tối đa được chọn từ mỗi vùng để đưa vào đối tượng đầu ra bản đồ

$$x^l_i = f\left(\sum_j w^l_{i,j} * x^{l-1}_j\right) \quad (2)$$

$$f(x) = \max(0, x) = \begin{cases} 0, & \text{if } x < 0 \\ x, & \text{if } x \geq 0 \end{cases} \quad (3)$$

Trong Hình 1, 12 hạt chập được sử dụng trong lớp chập thứ nhất và 28 hạt chập được sử dụng trong lớp chập thứ hai. Hai lớp FC tương ứng được bao gồm với 5488-D và 256-D. Phần đệm bằng không được sử dụng để có được cùng kích thước của bản đồ tính năng đầu vào/đầu ra. Hình 2 là sơ đồ của phần đệm bằng 0, trong đó các ô vuông có đường màu xanh biểu thị hình ảnh được thử nghiệm và các ô vuông có đường màu đỏ biểu thị cửa sổ  $5 \times 5$  của nhân tích chập.



**Hình 2.** Sơ đồ của phần đệm số 0

Trước khi đào tạo mạng tích chập, 2.000 mẫu trong tập dữ liệu chữ viết tay (Cơ sở dữ liệu MNIST về các chữ số viết tay) (Lecun và cộng sự 1998) được


sử dụng để thay đổi trình phân loại Softmax-6 thành Softmax-10 để huấn luyện trọng số của mạng tích chập, trong đó Softmax -10 là bộ phân loại để có được mười phân loại (các chữ số viết tay 0–9). Để có thêm thông tin trong bản đồ đặc trưng, kích thước  $28 \times 28$  của mẫu trong tập dữ liệu chữ viết tay được thay đổi kích thước thành kích thước  $56 \times 56$ . 1.720 mẫu đã thay đổi kích thước và 280 mẫu từ tập dữ liệu chữ viết tay lần lượt được sử dụng để huấn luyện và kiểm tra. Bộ học được sử dụng trong lớp nhóm thứ hai và lớp FC thứ hai và các tham số được đặt lần lượt là 0,3 và 0,5. Mục đích chính của việc sử dụng cơ sở dữ liệu MNIST gồm các chữ số viết tay trong quá trình đào tạo trước là khởi tạo các trọng số để dễ dàng đạt được sự hội tụ của các trọng số trong quá trình tinh chỉnh tiếp theo, epochs là 25. Các tham số của các lớp tích chập và gộp được liệt kê trong Bảng 1. Để đào tạo ShrimpNet được đề xuất, hàm mất mát của entropy chéo được sử dụng và xác định như trong biểu thức (4), trong đó  $y_i$  và  $y'$  lần lượt là lớp dự đoán và lớp thực trong ảnh thử nghiệm.

$$Loss = - \sum_i y'_i \log(y_i) \quad (4)$$

Khi thu được các trọng số ban đầu, các trọng số giữa lớp tích chập đầu tiên và lớp nhóm, lớp tích chập thứ hai và lớp nhóm được giữ nguyên. Softmax-10 được thay đổi thành Softmax-6, sau đó các trọng số khác trong ShrimpNet được tinh chỉnh bằng cách sử dụng bộ dữ liệu thu thập bao gồm sáu loại tôm khác nhau, epochs cũng là 25. Sáu loại tôm là *White shrimp*, *Giant river shrimp*, *Marsupenaeus japonicus*, *Procambarus clarkii*, *Peacock mantis shrimp*, and *Panulirus ornatus*, như trong Hình 3 được liệt kê từ trái sang phải và sau đó lần lượt từ trên xuống dưới. Cuối cùng, ShrimpNet đã được đào tạo và thử nghiệm có thể được sử dụng để nhận dạng thành công tôm.

**Bảng 1:** Parameters of convolutional and pooling layers

	Kernel size	Number of kernels	Stride size	Output size
Convolution 1	$5 \times 5$	12	1	$56 \times 56 \times 12$
Max pool 1	$2 \times 2$	–	2	$28 \times 28 \times 12$
Convolution 2	$5 \times 5$	28	1	$28 \times 28 \times 28$
Max pool 2	$2 \times 2$	–	2	$14 \times 14 \times 28$



**Hình 3.** Một số mẫu thuộc các loại khác nhau trong bộ dữ liệu tôm (*White shrimp*, *Giant river shrimp*, *Marsupenaeus japonicus*, *Procambarus clarkii*, *Peacock mantis shrimp*, and *Panulirus ornatus* lần lượt được liệt kê từ trái sang phải và sau đó từ trên xuống dưới)

**Bảng 2:** Bộ dữ liệu thu thập được

Loại Tôm	Số lượng
Tôm chân trắng	1000 Label

#### IV. Kết quả thí nghiệm


Các thử nghiệm được tiến hành trên máy tính có CPU Intel® Core™ i5-1035G1 CPU @ 1.00GHz(8CPUs), ~1.2GHz và 8GB RAM. Hệ điều hành là Windows 10 và các thuật toán đã được triển khai trong sổ ghi chép Python và Jupyter với gói thư viện Keras.

Tôm là mặt hàng thương mại quan trọng của thế giới, có giá trị kinh tế cao, trong đó tôm chân trắng chiếm 80% tổng sản lượng tôm toàn cầu. Do đó, loại tôm được chọn trong bộ dữ liệu tôm thu nhập bao gồm Tôm chân trắng. Bộ dữ liệu tôm được thu



thập từ hình ảnh, video của Google và video tự quay, được trình bày trong Bảng 2. Có tổng là 1000 mẫu trong bộ dữ liệu tôm. Trong bộ dữ liệu tôm là các hình ảnh được xoay các chiều khác nhau nhằm tăng khả năng trong việc nhận dạng tôm.

Đây là ví dụ về loại tôm trong bộ dữ liệu tôm.



Mẫu ảnh được sử dụng có kích thước 590x445 và được thay đổi kích thước đầu vào mô hình là 100x100 pixel. Sau đó ảnh sẽ được chuyển thành màu xám. Chúng tôi đã thực hiện Train cho mô hình và nhận được kết quả như sau:

```

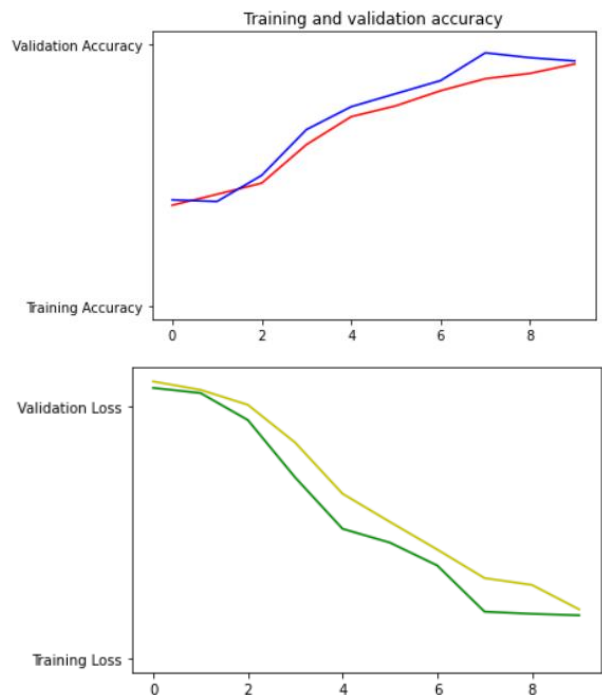
EPOCHS=10
history=model.fit(
    train_generator,
    steps_per_epoch=30,
    epochs=EPOCHS,
    verbose=1,
    validation_data=valid_generator,
    validation_steps=5
)

```

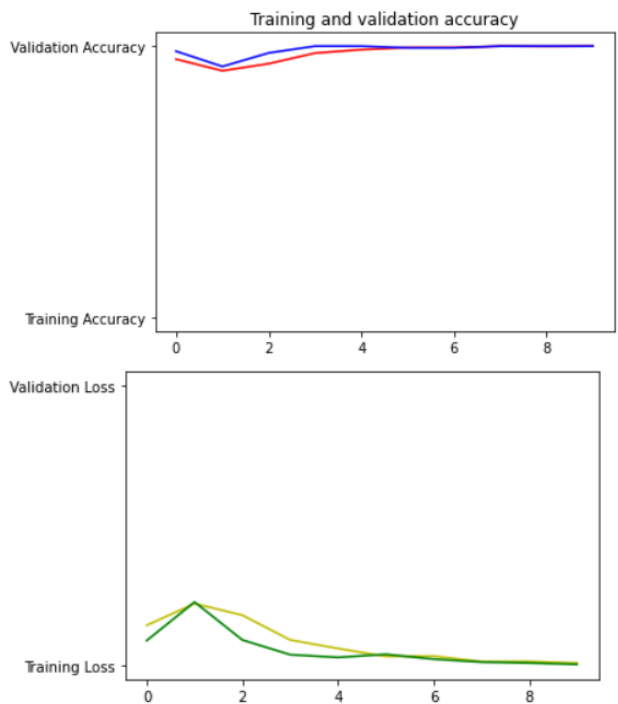
Epoch	Time	Loss	Accuracy	Val_Loss	Val_Accuracy
Epoch 1/10	14s 482ms/step	0.1428	0.9519	0.0883	0.981
Epoch 2/10	13s 437ms/step	0.2207	0.9092	0.2263	0.925
Epoch 3/10	13s 440ms/step	0.1791	0.9354	0.0904	0.975
Epoch 4/10	13s 437ms/step	0.0905	0.9744	0.0377	1.000
Epoch 5/10	13s 437ms/step	0.0599	0.9872	0.0280	1.000
Epoch 6/10	13s 437ms/step	0.0315	0.9947	0.0390	0.993
Epoch 7/10	13s 431ms/step	0.0326	0.9947	0.0218	0.993
Epoch 8/10	13s 437ms/step	0.0131	1.0000	0.0113	1.000
Epoch 9/10	14s 471ms/step	0.0134	0.9989	0.0080	1.000
Epoch 10/10	13s 442ms/step	0.0076	1.0000	0.0030	1.000

Bảng thống kê giá trị Accuracy và Loss đại diện cho các giá trị Train của mô hình để cho thấy quá trình học của máy, lần lượt là Train lần 1 và lần 2

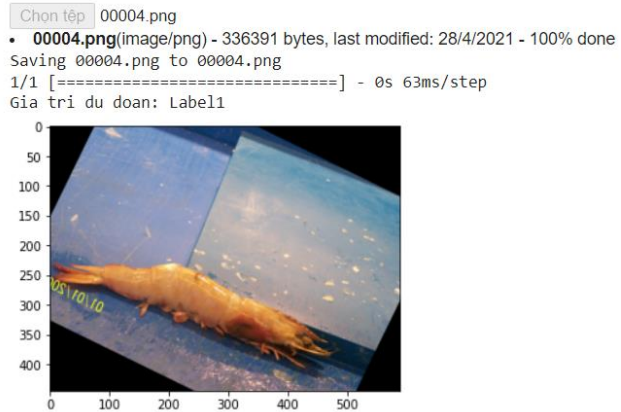
Lần 1:



Lần 2:



Sau hai lần Train chúng tôi đã thử nghiệm nhận dạng một vài bức ảnh để chứng minh rằng mô hình đã hoạt động hiệu quả với các giá trị chính xác lên tới 100%



Có thể thấy, các mẫu tôm nhận diện ngày càng đúng, các giá trị Accuracy ngày càng lên tới 100% và cho thấy mô hình được sử dụng đang hoạt động tốt trong công việc nhận diện.

## V. Kết luận

Kiến trúc học sâu (Deep Learning) sử dụng phương thức CNN được đề xuất để nhận dạng tôm khi xem xét quá trình và mức độ sử dụng phần cứng. Mô hình sử dụng CNN có 3 lớp và 2 lớp Dense được sử dụng để đạt hiệu quả tốt hơn trong việc nhận dạng tôm. Có 32 tích chập(Kernel) trong lớp tích chập thứ nhất, 63 lớp tích chập(Kernel) trong lớp tích chập thứ hai và 128 lớp tích chập(Kernel) trong lớp tích chập thứ ba. Hai lớp FC với 521-D và 3-D. Kết quả cho thấy mô hình CNN sử dụng có độ chính xác lên tới 100% trong việc nhận dạng tôm theo bộ, chúng ta hoàn toàn có thể thu thập thêm các loại tôm khác nhau và cũng sẽ nhận được các kết quả gần như hoàn toàn đúng với loại tôm này. Thông qua đó chúng ta có thể áp dụng mô hình vào thực tiễn trong việc nuôi tôm thông minh hoặc có thể phát triển thêm về nhận diện hành vi trong tương lai.

## Tài liệu tham khảo:

1. <https://www.youtube.com/watch?v=MhkZxcsutU0&t=455s>
2. <https://www.kaggle.com/datasets/crowww/a-large-scale-fish-dataset>

3. <https://www.youtube.com/watch?v=gv693bG9K98>